
# BPR: Bayesian Personalized Ranking from Implicit Feedback

**Sangmin Park** 

### Contents

#### Introduction




Main Idea

# Introduction : Implicit feedback

**Explicit Feedback** 

**Implicit Feedback** 





더 가시적이다.

더 얻기 쉽다.



# Introduction: purpose

#### **MF(Matrix Factorization)**

User x Item Matrix에 latent features를 고려함으로써 User matrix, Item matrix로 분해하여 예측한다.

#### **KNN**(k-nearest-neighbor)

Similarity matrix를 기준으로 k개의 인접한 데이터를 기반하여 예측한다.

이전의 연구는 특정 item에 대한 구매 여부에 관심이 있었다면,

위 연구는 items 사이의 선호도에 기반한 Personalized Ranking에 더욱 중점을 둔다.

# Introduction: map

$$p(\theta|y) = \frac{p(y|\theta)p(\theta)}{p(y)}$$

$$= \frac{p(y|\theta)p(\theta)}{\int_{\theta} p(y|\theta)p(\theta)d\theta} \qquad \left(\because p(y) = \int_{\theta} p(y|\theta)p(\theta)d\theta\right)$$

$$\propto p(y|\theta)p(\theta)$$


 $p(\theta)$ : Prior - subjective belief about  $\theta$ 

 $p(y|\theta)$ : Likelihood – observation (data) regarding  $\theta$ 

 $p(\theta|y)$ : Posterior - Updated belief about  $\theta$  with the data

### Introduction: Roc & Auc

	Predicted: Abnormal	Predicted: Normal
Actual: Abnormal	True Positive	False Negative
Actual: Normal	False Positive	True Negative



BPR: Main Idea

U: 모든 users

I : 모든 items


 $S \subseteq U \times I$ : Implicit feedback이 관찰된 (u,i) 쌍의 집합

*Iu* +: : user u가 implicit feedback을 남긴 items


Ui + : item i에 implicit feedback을 남긴 users

>u : user u의 선호도 비교


$$\forall i, j \in I : i \neq j \Rightarrow i >_u j \lor j >_u i$$
 (totality)  
 $\forall i, j \in I : i >_u j \land j >_u i \Rightarrow i = j$  (antisymmetry)  
 $\forall i, j, k \in I : i >_u j \land j >_u k \Rightarrow i >_u k$  (transitivity)



기존의 연구는 user x item matrix에 대해 각각의 선호도를 알아보며 sorting을 진행하는 방식이었다. 이에 따라 정말로 관심이 없는 negative implicit feedback과 나중에 구매할 의향이 있을 future missing value를 구분하지 않고 모두 0으로 간주하게 되었다.




각 user 별로 item끼리 비교를 하면서 선호 정도를 직접적으로 알아보자.



#### 3가지 가정

- 1. 관측된 item은 관측되지 않은 item보다 선호된다.
- 2. 관측된 item사이 비교는 불가능하다.
- 3. 관측되지 않은 item사이의 비교 역시 불가능하다.

이전과 달리 negative feedback과 missing value가 구분된다.



$$D_S := \{(u, i, j) | i \in I_u^+ \land j \in I \setminus I_u^+ \}$$

∧: and ∨: or \: minus

$$p(\Theta|>_u) \propto p(>_u|\Theta) p(\Theta)$$

$$\prod_{u \in U} p(>_{u} |\Theta) = \prod_{(u,i,j) \in U \times I \times I} p(i>_{u} j|\Theta)^{\delta((u,i,j) \in D_{S})} 
\cdot (1 - p(i>_{u} j|\Theta))^{\delta((u,j,i) \notin D_{S})}$$

$$\delta(b) := \begin{cases} 1 & \text{if } b \text{ is true,} \\ 0 & \text{else} \end{cases}$$

각 User끼리 가지는 item들에 대한 선호도는 independet.

각 Item pair끼리의 비교 순서 역시 independent.

$$p(\Theta|>_u) \propto p(>_u|\Theta) p(\Theta)$$

$$\prod_{u \in U} p(>_u |\Theta) = \prod_{(u,i,j) \in U \times I \times I} p(i>_u j|\Theta)^{\delta((u,i,j) \in D_S)} \cdot (1 - p(i>_u j|\Theta))^{\delta((u,j,i) \notin D_S)}$$

$$\prod_{u \in U} p(>_u |\Theta) = \prod_{(u,i,j) \in D_S} p(i>_u j|\Theta)$$
 By totality, antisymmetry

$$\prod_{u \in U} p(>_u |\Theta) = \prod_{(u,i,j) \in D_S} p(i>_u j|\Theta)$$

$$p(i >_u j | \Theta) := \sigma(\hat{x}_{uij}(\Theta))$$

#### Sigmoid function + real-valued function

Properties 충족

u,i,j 사이 relationship estimate.

Ex) MF, KNN

$$p(\Theta) \sim N(0, \Sigma_{\Theta})$$

$$\Sigma_{\Theta} = \lambda_{\Theta} I$$


$$N(\Theta|\mu,\Sigma) = rac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}}exp(-rac{1}{2}(\Theta-\mu)^T\Sigma^{-1}(\Theta-\mu))$$

$$\propto exp(-\frac{1}{2}\Theta^{T}(\frac{1}{\lambda_{\Theta}}I)\Theta)$$

$$= exp(-\frac{1}{2\lambda_{\Theta}}\Theta^{T}\Theta) \simeq exp(-\lambda_{\Theta}\|\Theta\|^{2})$$

$$\begin{aligned} \text{BPR-OPT} &:= \ln \, p(\Theta|>_u) \\ &= \ln \, p(>_u|\Theta) \, p(\Theta) \\ &= \ln \, \prod_{(u,i,j) \in D_S} \sigma(\hat{x}_{uij}) \, p(\Theta) \\ &= \sum_{(u,i,j) \in D_S} \ln \sigma(\hat{x}_{uij}) + \ln p(\Theta) \\ &= \sum_{(u,i,j) \in D_S} \ln \sigma(\hat{x}_{uij}) - \lambda_{\Theta} ||\Theta||^2 \end{aligned}$$

# Main Idea: AUC analogy



$$AUC(u) := \frac{1}{|I_u^+| |I \setminus I_u^+|} \sum_{i \in I_u^+} \sum_{j \in |I \setminus I_u^+|} \delta(\hat{x}_{uij} > 0)$$


$$AUC := \frac{1}{|U|} \sum_{u \in U} AUC(u)$$

$$AUC(u) = \sum_{(u,i,j)\in D_S} z_u \,\delta(\hat{x}_{uij} > 0) \qquad \qquad \delta(x>0) = H(x) := \begin{cases} 1, & x>0 \\ 0, & \text{else} \end{cases}$$

z와 loss function만의 차이를 보인다.

# Main Idea: AUC analogy

#### **Loss functions**



# Main Idea: BPR Learning Algorithm

$$\frac{\partial \text{BPR-OPT}}{\partial \Theta} = \sum_{(u,i,j) \in D_S} \frac{\partial}{\partial \Theta} \ln \sigma(\hat{x}_{uij}) - \lambda_{\Theta} \frac{\partial}{\partial \Theta} ||\Theta||^2$$

$$\propto \sum_{(u,i,j) \in D_S} \frac{-e^{-\hat{x}_{uij}}}{1 + e^{-\hat{x}_{uij}}} \cdot \frac{\partial}{\partial \Theta} \hat{x}_{uij} - \lambda_{\Theta} \Theta$$

#### **Full gradient descent**

계산량이 많다.

learning rate를 낮게 잡아야한다. (observed data << non ovserved data ; skewness of x\_uij)

#### **Stochastic Gradient descent with Bootstrap**

계산량이 상대적으로 적다.

User-wise, item-wise같이 consecutive한 update을 가능한 회피한다.

조기종료 가능



$$\hat{x}_{uij} := \hat{x}_{ui} - \hat{x}_{uj}$$

x\_ui, x\_uj를 MF/KNN을 접목하여 얻고, **둘의 차를 criterion**으로 두어 optimize한다.

### Main Idea: BPR with MF

$$\hat{X} := WH^t \quad W : |U| \times k \qquad H : |I| \times k$$

$$\hat{x}_{ui} = \langle w_u, h_i \rangle = \sum_{f=1}^k w_{uf} \cdot h_{if}$$

$$\frac{\partial}{\partial \theta} \hat{x}_{uij} = \begin{cases} (h_{if} - h_{jf}) & \text{if } \theta = w_{uf}, \\ w_{uf} & \text{if } \theta = h_{if}, \\ -w_{uf} & \text{if } \theta = h_{jf}, \\ 0 & \text{else} \end{cases}$$

### Main Idea: BPR with KNN

$$\hat{x}_{ui} = \sum_{l \in I_u^+ \land l \neq i} c_{il}$$

 $\hat{x}_{ui} = \sum_{Cil} c_{il}$   $C: I \times I$  item-similarity matrix

$$c_{i,j}^{\text{cosine}} := \frac{|U_i^+ \cap U_j^+|}{\sqrt{|U_i^+| \cdot |U_j^+|}}$$

$$\frac{\partial}{\partial \theta} \hat{x}_{uij} = \begin{cases} +1 & \text{if } \theta \in \{c_{il}, c_{li}\} \land l \in I_u^+ \land l \neq i, \\ -1 & \text{if } \theta \in \{c_{jl}, c_{lj}\} \land l \in I_u^+ \land l \neq j, \\ 0 & \text{else} \end{cases}$$

### Main Idea: BPR vs WRMF

$$\sum_{u \in U} \sum_{i \in I} c_{ui} (\langle w_u, h_i \rangle - 1)^2 + \lambda ||W||_f^2 + \lambda ||H||_f^2$$

SVD + regularization term (overfitting 방지) Weights on Positive implicit feedback

그러나 **one – item level** (not pair)이고 SVD(square-loss)기반은 quantative problem에 적합하기에 Qualitative(classification) problem에 logistic approach보다 불리하다.

### Main Idea: BPR vs MMMF

$$\sum_{(u,i,j)\in D_s} \max(0, 1 - \langle w_u, h_i - h_j \rangle) + \lambda_w ||W||_f^2 + \lambda_h ||H||_f^2$$

Explicit feedback기반 approach.

Matrix factorization만이 접목 가능(범용성이 상대적으로 낮다.)

### Main Idea: Evaluation


AUC = 
$$\frac{1}{|U|} \sum_{u} \frac{1}{|E(u)|} \sum_{(i,j) \in E(u)} \delta(\hat{x}_{ui} > \hat{x}_{uj})$$

LOO scheme 이용.


Rated Users<10 인 Items or Rating Items < 10 Users는 제외.

### Main Idea: Conclusion

#### Online shopping: Rossmann



#### Video Rental: Netflix



### Main Idea: Conclusion

SVD-MF,WR-MF,BPR-MF 모두 MF를 활용하였으나 그 중에서 특히 BPR-MF의 AUC 값이 월등히 높았다.

어떠한 criterion을 가지고 optimize하는지가 굉장히 중요하다.
Ranking에 대해서는 pair끼리의 비교를 기준으로 하는 것이 유효하다.

**BPR**: Implementation

# Implementation: Preprocessing

```
ratings = pd.read_csv(os.path.join(INPUT_DIR, 'ratings.csv'))
ratings_df = ratings.drop(columns=['timestamp'])

#userId x moveId , cell : rating인 matrix
table_df = ratings_df.pivot_table(index='userId', columns='movieId', values ='rating')
df_matrix = table_df.to_numpy()
df_matrix = np.nan_to_num(df_matrix)

#implicit : 0과 1로만 표현
df_matrix[df_matrix>0]=1
```

User x item matrix >> Item x Item matrix (each users)
Binary to be Implicit

# Implementation: Preprocessing

```
row_sums = np.sum(df_matrix,axis=1)
col_sums = np.sum(df_matrix,axis=0)
row_keep = row_sums>=10
col keep = col sums>=10
user_movie_data = df_matrix[row_keep][:,col_keep]
test set = np.zeros(user movie data.shape)
test_pair = []
for row in range (user_movie_data.shape[0]):
  test_ele = np.random.randint(0,user_movie_data.shape[1])
  test set[row][test ele] = user movie data[row][test ele]
  user_movie_data[row][test_ele] = 0
  test_pair.append([row,test_ele])
```

Rate users < 10 Items & Rate Items < 10 Users 배제 Test data를 loo scheme으로 구성.

# Implementation : BPR-MF

```
class BPR_MF:
    def __init__(self,learning_rate = 0.01, features = 20, lbd = 0.01, data = None):
        self.learning_rate = learning_rate
        self.features = features
        self.lbd = lbd
        self.data = data
        self.user_feat = None
        self.item_feat = None
        print("features")
        print(self.features)
```

# Implementation: BPR-MF

```
def fit(self):
#일단 user x feature, item x feature를 초기에 random하게 생성
user_feat = np.random.random((self.data.shape[0],self.features))
item_feat = np.random.random((self.data.shape[1],self.features))
auc = []
predicted = []
truevalue = []
epochs = []
```

# Implementation: BPR-MF

```
for itr in range(1000001):
 u = np.random.choice(range(self.data.shape[0]))
 u_feat = copy.deepcopy(self.data[u])
  i = np.random.choice(np.where(u_feat==1)[0])
  j = np.random.choice(np.where(u_feat==0)[0])
 w u = user feat[u,:]
 h_i = item_feat[i,:]
 h_j = item_feat[j,:]
 \times uij = np.dot(w u,h i) - np.dot(w u,h j)
  exp = np.exp(-x uii) / (1 + np.exp(-x uii))
 grad_wu = exp * (h_i-h_j) + self.lbd * w_u
 user_feat[u,:] = user_feat[u,:] + self.learning_rate * grad_wu
  grad_hi = exp * (w_u) + self.lbd * h_i
  item_feat[i,:] = item_feat[i,:] + self.learning_rate * grad_hi
  grad_hj = exp * (-w_u) + self.lbd * h_j
  item_feat[j,:] = item_feat[j,:] + self.learning_rate * grad_hj
```

$$\frac{\partial}{\partial \theta} \hat{x}_{uij} = \begin{cases} (h_{if} - h_{jf}) & \text{if } \theta = w_{uf}, \\ w_{uf} & \text{if } \theta = h_{if}, \\ -w_{uf} & \text{if } \theta = h_{jf}, \\ 0 & \text{else} \end{cases}$$



```
if(x_uij>0):
   predicted.append(1)
 else:
   predicted.append(0)
 #해당 유저의 movie i와 movie j를 비교해서 보자.
  if(self.data[u][i]==1 and self.data[u][j]==0):
   truevalue.append(1)
 else:
   truevalue.append(0)
  if(itr%100000==0):
    if not(sum(truevalue)==0 and itr !=0):
     epochs.append(itr)
     auc.append(sum(predicted)/sum(truevalue))
     print(str(itr) + "th auc is : " + str(auc[-1]))
self.user_feat = user_feat
self.item_feat = item_feat
return epochs, auc
```

Training data set에 대하여 AUC 계산

# Implementation : BPR-MF

```
def test(self,pair,test_set):
 #pair에 있는 애들만 가지고 진행한다.
 test_predict=[]
 gr_truth = []
 tst_epchs = []
 rss = 0
 auc test = 0
 for m in range(len(pair)):
   #나머지 중에 item고르기
   num_range = np.array(list(range(len(pair))))
   filter_num = np.delete(num_range, np.where(num_range==pair[m][1]))
   another = np.random.choice(filter_num)
   test_user_feat = self.user_feat[m,:]
   test_i_feat = self.item_feat[pair[m][1],:]
   test_j_feat = self.item_feat[another,:]
   test_xuij = np.dot(test_user_feat,test_i_feat) - np.dot(test_user_feat,test_j_feat)
```

만들어진 train matrix에 대입

# Implementation : BPR-MF

```
if(test_set[m][pair[m][1]]==1 and self.data[m][another]==0):
    gr_truth.append(1)
    if(test_xuij>0):
        test_predict.append(1)
    else:
        test_predict.append(0)

auc_test = np.sum(test_predict)/np.sum(gr_truth)
    return auc_test
```

Ground truth이 1인 경우에 prediction은 어떤 결과를 도출했는지를 비율로써 비교한다.

```
class BPR_KNN:
    def __init__(self,learning_rate = 0.01, lbd = 0.01, data = None):
        self.learning_rate = learning_rate
        self.lbd = lbd
        self.data = data
        self.c_item = np.random.random((self.data.shape[1],self.data.shape[1]))
```



```
u = np.random.choice(range(self.data.shape[0]))
u_feat = copy.deepcopy(self.data[u])
i = np.random.choice(np.where(u_feat==1)[0])
i = np.random.choice(np.where(u feat==0)[0])
#C에서 읽도록 u가 ratings에서 (i제외) 평가했던 항목들의 위치를 읽어온다.
compare_list_temp_i = np.nonzero(self.data[u])[0]
compare_location_i = compare_list_temp_i[compare_list_temp_i!=i]
#c_il 들 의 위치를 위해 우선 ith row를 지정하고 나머지는 compare list의 위치로 찾아준다.
compare_list_i = self.c_item[i][compare_location_i]
x_ui = np.sum(compare_list_i)
#i에대해 동일과정 반복. [0]은 (list.공백)인 형태로 나와서 해준거다.
compare_list_temp_j = np.nonzero(self.data[u])[0]
compare_location_j = compare_list_temp_j[compare_list_temp_j!=j]
compare_list_j = self.c_item[j][compare_location_j]
x_uj = np.sum(compare_list_j)
x uii = x ui - x ui
```

$$\hat{x}_{ui} = \sum_{l \in I_u^+ \land l \neq i} c_{il}$$



```
u = np.random.choice(range(self.data.shape[0]))
u_feat = copy.deepcopy(self.data[u])
i = np.random.choice(np.where(u_feat==1)[0])
i = np.random.choice(np.where(u feat==0)[0])
#C에서 읽도록 u가 ratings에서 (i제외) 평가했던 항목들의 위치를 읽어온다.
compare_list_temp_i = np.nonzero(self.data[u])[0]
compare_location_i = compare_list_temp_i[compare_list_temp_i!=i]
#c_il 들 의 위치를 위해 우선 ith row를 지정하고 나머지는 compare list의 위치로 찾아준다.
compare_list_i = self.c_item[i][compare_location_i]
x_ui = np.sum(compare_list_i)
#i에대해 동일과정 반복. [0]은 (list.공백)인 형태로 나와서 해준거다.
compare_list_temp_j = np.nonzero(self.data[u])[0]
compare_location_j = compare_list_temp_j[compare_list_temp_j!=j]
compare_list_j = self.c_item[j][compare_location_j]
x_uj = np.sum(compare_list_j)
x uii = x ui - x ui
```

$$\hat{x}_{ui} = \sum_{l \in I_u^+ \land l \neq i} c_{il}$$

```
x_uij = x_ui-x_uj

exp = np.exp(-x_uij) / (1 + np.exp(-x_uij))

grad_ci = exp * 1 + self.lbd * self.c_item[i, compare_location_i]

grad_cj = exp * (-1) + self.lbd * self.c_item[j, compare_location_j]


#이제 갱신을 해주었다. c를

self.c_item[i,compare_location_i] = self.c_item[i,compare_location_i] + self.learning_rate * grad_ci

self.c_item[j,compare_location_j] = self.c_item[j,compare_location_j] + self.learning_rate * grad_cj
```


$$\frac{\partial}{\partial \theta} \hat{x}_{uij} = \begin{cases} +1 & \text{if } \theta \in \{c_{il}, c_{li}\} \land l \in I_u^+ \land l \neq i, \\ -1 & \text{if } \theta \in \{c_{jl}, c_{lj}\} \land l \in I_u^+ \land l \neq j, \\ 0 & \text{else} \end{cases}$$

# Implementation : BPR-MF



Train AUC: 0.81

Test AUC: 0.59



Train AUC: 0.88

Test AUC: 0.64

# Implementation : COSINE-KNN

```
class COSINE_KNN:
    def __init__(self,learning_rate = 0.01, lbd = 0.01, data = None):
        self.learning_rate = learning_rate
        self.lbd = lbd
        self.data = data
        item_data = data.T
        product = np.dot(item_data,item_data.T)
        product_norm = np.linalg.norm(product, ord=1, axis=1, keepdims=True)
        norm = np.linalg.norm(item_data, ord=1, axis=1, keepdims=True)
        self.c = product / np.sqrt(norm * norm.T)
```

Train AUC: 0.88

Test AUC: 0.55



